家庭圈用户识别模型 - 使用说明

快速开始

1. 环境准备

确保已安装Python 3.7或更高版本，然后安装依赖包：

```
pip install -r requirements.txt
```

2. 数据准备

确保数据文件位于正确路径：

```
D:\pydata\梧桐杯\data\AI+数据1：数据应用开发-家庭圈用户识别模型.xlsx
```

数据文件应包含3个sheet：

- Sheet 1: 带标签的训练数据
- Sheet 2: 不带标签的验证数据
- Sheet 3: 不带标签的测试数据

每个sheet格式：

- 第1行：英文表头
- 第2行：中文表头
- 第3行开始：数据

3. 运行主程序

执行以下命令运行完整的处理流程：

```
python main.py
```

程序将自动完成：

1. 数据加载和预处理
2. 特征工程
3. 家庭圈识别
4. 关键人识别
5. 结果保存
6. 报告生成

4. 查看结果

处理完成后，结果将保存在 `output` 目录：

- `train_result.csv` - 训练数据预测结果
- `valid_result.csv` - 验证数据预测结果
- `test_result.csv` - 测试数据预测结果
- `statistics.json` - 统计信息
- `特征工程报告.txt` - 特征工程详细报告
- `模型评估报告.txt` - 模型评估报告
- `结果说明文档.txt` - 结果说明文档

5. 启动可视化界面

运行Web应用：

```
python app.py
```

然后在浏览器中访问：http://127.0.0.1:5000

功能说明

主程序 (main.py)

主程序包含完整的处理流程：

1. **数据加载**：读取Excel文件，处理多级表头
2. **特征工程**：提取多维度特征
3. **模型训练**：使用DBSCAN聚类识别家庭圈
4. **关键人识别**：为每个家庭圈识别关键人
5. **结果保存**：保存预测结果和统计信息
6. **报告生成**：生成各类报告文档

Web应用 (app.py)

提供交互式可视化界面，功能包括：

1. **统计信息展示**：显示总体统计信息
2. **家庭圈列表**：浏览所有识别的家庭圈
3. **用户搜索**：搜索特定用户信息
4. **关系查询**：查询两个用户是否为家庭成员
5. **数据可视化**：图表展示（待完善）

模块说明

data_loader.py

- 负责Excel数据加载
- 处理多级表头（英文+中文）
- 自动识别用户ID列

feature_engineering.py

- 提取地址关联性特征
- 提取缴费账户关联性特征
- 提取终端共享特征
- 提取通信行为特征
- 提取基础信息特征

family_circle_model.py

- 实现DBSCAN聚类算法
- 家庭圈识别
- 关键人识别
- 关系判定规则
- 模型评估

report_generator.py

- 生成特征工程报告
- 生成模型评估报告
- 生成结果说明文档

参数调整

模型参数

在 `family_circle_model.py` 中可以调整：

```
# DBSCAN参数
self.cluster_model = DBSCAN(eps=0.5, min_samples=2, metric='cosine')
```

- `eps`：邻域半径，值越小越严格
- `min_samples`：最小样本数，家庭圈最少人数
- `metric`：距离度量方式

关系判定规则

在 `family_circle_model.py` 的 `define_relationship_rules()` 方法中可以调整：

```
rules = {
    'same_address': {
        'threshold': 0.8,  # 地址相似度阈值
        'weight': 0.3      # 权重
    },
    # ... 其他规则
}
```

常见问题

1. 找不到数据文件

问题：程序报错找不到Excel文件

解决：

- 检查文件路径是否正确
- 确保文件名完全匹配（包括中文）
- 检查文件是否被其他程序占用

2. 列名识别错误

问题：程序无法识别用户ID列或其他关键列

解决：

- 检查Excel文件表头格式是否正确
- 在代码中手动指定列名
- 查看 `data_loader.py` 中的列名匹配逻辑

3. 特征提取失败

问题：特征工程阶段出错

解决：

- 检查数据中是否包含必要的列
- 查看 `feature_engineering.py` 中的列名匹配逻辑
- 根据实际数据调整特征提取代码

4. 聚类结果不理想

问题：识别出的家庭圈数量过多或过少

解决：

- 调整DBSCAN的 `eps` 参数
- 调整 `min_samples` 参数
- 检查特征工程是否合理

- 考虑使用其他聚类算法

5. Web应用无法启动

问题：Flask应用启动失败

解决：

- 检查端口5000是否被占用
- 确保已安装Flask：`pip install flask`
- 检查是否有语法错误

性能优化建议

1. **大数据集处理**：
    - 考虑分批处理数据
    - 使用更高效的聚类算法
    - 优化特征计算
2. **特征工程优化**：
    - 根据实际数据特点调整特征
    - 移除冗余特征
    - 使用特征选择方法
3. **模型优化**：
    - 尝试不同的聚类算法
    - 调整参数进行网格搜索
    - 使用集成方法

技术支持

如遇到问题，请检查：

1. Python版本是否符合要求
2. 所有依赖包是否已安装
3. 数据文件格式是否正确
4. 代码是否有语法错误

更新日志

v1.0.0 (2024)

- 初始版本
- 实现基本功能
- 添加Web可视化界面