家庭圈用户识别模型 - 项目总结

项目概述

本项目实现了基于多维度数据的家庭圈用户识别模型，能够准确界定家庭范围，识别家庭成员，并确定家庭关键人信息。项目完全符合赛题要求，包含特征工程、模型构建、评估和可视化等完整功能。

技术架构

1. 数据层

- **数据加载模块**（`data_loader.py`）
  - 处理Excel多级表头（英文+中文）
  - 自动识别用户ID列
  - 数据预处理和清洗

2. 特征工程层

- **特征提取模块**（`feature_engineering.py`）
  - 地址关联性特征提取
  - 缴费账户关联性特征提取
  - 终端共享特征提取
  - 通信行为特征提取
  - 基础信息特征提取

3. 模型层

- **家庭圈识别模型**（`family_circle_model.py`）
  - DBSCAN聚类算法
  - 关系判定规则
  - 关键人识别算法
  - 模型评估功能

4. 应用层

- **主程序**（`main.py`）
  - 完整处理流程
  - 结果保存
  - 报告生成
- **Web可视化**（`app.py` + `templates/index.html`）
  - 交互式界面
  - 数据查询
  - 结果展示

5. 报告层

- **报告生成器**（`report_generator.py`）
  - 特征工程报告
  - 模型评估报告
  - 结果说明文档

核心算法

1. 特征工程策略

地址关联性特征

- 相同地址的用户数量统计
- 地址稳定性指标
- 节假日驻留基站相似度

缴费账户关联性特征

- 相同缴费账户的用户数量
- 账户共享关系强度
- 缴费行为模式

终端共享特征

- 共享设备数量
- 设备共享关系网络
- 终端使用模式

通信行为特征

- 通话频率统计
- 联系人重叠度
- 通信时间模式相似度

2. 家庭圈识别算法

采用DBSCAN（基于密度的聚类）算法：

- **优点**：能够发现任意形状的簇，适合家庭圈识别
- **参数**：
  - `eps=0.5`：邻域半径
  - `min_samples=2`：最小样本数（家庭圈最少2人）
  - `metric='cosine'`：使用余弦距离度量

3. 关键人识别算法

基于多维度特征计算关键度得分：

1. 账户主特征（权重高）
2. 缴费特征（权重最高）
3. 通信中心度
4. 地址稳定性

每个家庭圈中得分最高的用户被识别为关键人。

4. 关系判定规则

综合多维度信息进行关系判定：

维度	阈值	权重	说明
地址关联性	0.8	0.3	地址相似度≥80%
缴费账户关联性	1.0	0.4	完全相同的账户
终端共享特征	1	0.2	至少共享1个设备
通信行为特征	0.5	0.1	通信频率相似度≥50%

综合判定阈值：0.5（加权得分≥50%判定为家庭成员）

实现特点

1. 多维度特征融合

- 综合考虑地址、账户、设备、通信等多维度信息
- 特征权重可配置
- 支持特征扩展

2. 无监督学习

- 使用DBSCAN聚类，无需大量标注数据
- 自动发现家庭圈边界
- 适应不同数据分布

3. 规则与模型结合

- 结合规则判定和机器学习模型
- 提供关系置信度
- 可解释性强

4. 完整的评估体系

- 准确率、精确率、召回率、F1值
- 目标：核心关系识别准确率≥85%
- 详细的评估报告

5. 交互式可视化

- Web界面友好易用
- 支持多数据集切换
- 实时查询和展示

项目结构

```
梧桐杯/
├── data/                                    # 数据目录
│   └── AI+数据1：数据应用开发-家庭圈用户识别模型.xlsx
├── output/                                  # 输出目录
│   ├── train_result.csv                    # 训练数据预测结果
│   ├── valid_result.csv                    # 验证数据预测结果
│   ├── test_result.csv                     # 测试数据预测结果
│   ├── statistics.json                     # 统计信息
│   ├── 特征工程报告.txt                    # 特征工程报告
│   ├── 模型评估报告.txt                    # 模型评估报告
│   └── 结果说明文档.txt                    # 结果说明文档
├── templates/                               # Web模板目录
│   └── index.html                          # 可视化界面
├── data_loader.py                          # 数据加载模块
├── feature_engineering.py                  # 特征工程模块
├── family_circle_model.py                  # 家庭圈识别模型
├── main.py                                 # 主程序
├── app.py                                  # Flask Web应用
├── report_generator.py                     # 报告生成器
├── requirements.txt                        # 依赖包
├── README.md                               # 项目说明
├── 使用说明.md                             # 使用说明
└── 项目总结.md                             # 本文档
```

使用流程

1. **数据准备**：确保Excel文件格式正确
2. **运行主程序**：`python main.py`
3. **查看结果**：检查`output`目录下的结果文件
4. **启动Web界面**：`python app.py`
5. **查看报告**：阅读生成的各类报告

技术亮点

1. **智能列名识别**：自动识别用户ID列和各类特征列
2. **多级表头处理**：正确处理Excel的英文+中文表头

3. **特征自动提取**：根据列名自动识别和提取特征
4. **灵活的参数配置**：模型参数和规则阈值可调整
5. **完整的文档体系**：提供详细的使用说明和报告

符合赛题要求

✅ 特征工程

- ☑ 充分挖掘多源数据中的有效特征
- ☑ 地址关联性特征
- ☑ 缴费账户关联性特征
- ☑ 终端共享特征
- ☑ 通信行为特征

✅ 关系定义

- ☑ 明确各类家庭成员关系的判定规则
- ☑ 定义判定阈值
- ☑ 提供关系置信度

✅ 模型构建

- ☑ 构建家庭圈用户识别模型
- ☑ 准确界定家庭范围
- ☑ 识别家庭成员
- ☑ 确认家庭关键人信息

✅ 模型评估

- ☑ 模型评估报告
- ☑ 准确率、召回率、F1值等关键指标
- ☑ 目标：核心关系识别准确率≥85%

✅ 结果输出

- ☑ 家庭圈用户群体划分结果
- ☑ 说明文档
- ☑ 特征工程报告
- ☑ 模型评估报告

✅ 可视化展示

- ☑ 可交互式的Web软件产品
- ☑ 智能查询功能
- ☑ 结果解读功能
- ☑ 数据可视化

未来优化方向

1. **特征工程优化**
   - 使用更高级的特征选择方法
   - 引入时间序列特征
   - 考虑特征交互
2. **模型优化**
   - 尝试其他聚类算法（如谱聚类、层次聚类）
   - 使用集成方法
   - 深度学习模型
3. **性能优化**
   - 大数据集分批处理
   - 并行计算
   - 缓存机制
4. **功能扩展**
   - 更丰富的可视化图表
   - 导出功能
   - 批量查询
   - API接口

总结

本项目完整实现了家庭圈用户识别模型，从数据加载、特征工程、模型构建到结果可视化的全流程。代码结构清晰，功能完整，符合赛题的所有要求。项目具有良好的可扩展性和可维护性，可以根据实际需求进行进一步优化和扩展。